먼저 환경을 Non-deterministic grid-world로 프로그램을 수정하였습니다.

Transition Probability는 환경이 주는 값이기 때문에 environment 파일을 수정해 줍니다.

```
WIDTH = 5  # 그리드월드 가로
Transition_prob = 0.8

class Env(tk.Tk):
    def __init__(self):
        super(Env, self).__init__()
        self.action_space = ['u', 'd', 'l', 'r']
        self.n_actions = len(self.action_space)
        self.title('Q Learning')
        self.geometry('{0}x{1}'.format(HEIGHT * UNIT, HEIGHT * UNIT))
        self.shapes = self.load_images()
        self.canvas = self._build_canvas()
        self.texts = []
        self.transition_prob = Transition_prob
```

Env 클래스에 Transition_prob변수를 선언, 초기화 해주었습니다.

```
def step(self, action):
    state = self.canvas.coords(self.rectangle)
    base_action = np.array([0, 0])
    if np.random.rand() > self.transition_prob:
        action = np.random.randint(4)
    self.render()
    if action == 0:  # 상
        if state[1] > UNIT:
            base_action[1] -= UNIT
    elif action == 1:  # 하
        if state[1] < (HEIGHT - 1) * UNIT:
            base_action[1] += UNIT
    elif action == 2:  # 좌
        if state[0] > UNIT:
            base_action[0] -= UNIT
    elif action == 3:  # 우
        if state[0] < (WIDTH - 1) * UNIT:
            base_action[0] += UNIT
```

이후 step 함수에서 작은확률에 의해 매개변수로 들어온 action이 상,하,좌,우 중 하나의 random 한 행동으로 바뀌게 구현해 주었습니다.

이렇게 환경을 바꾸고 프로그램을 실행시켜 보았습니다.

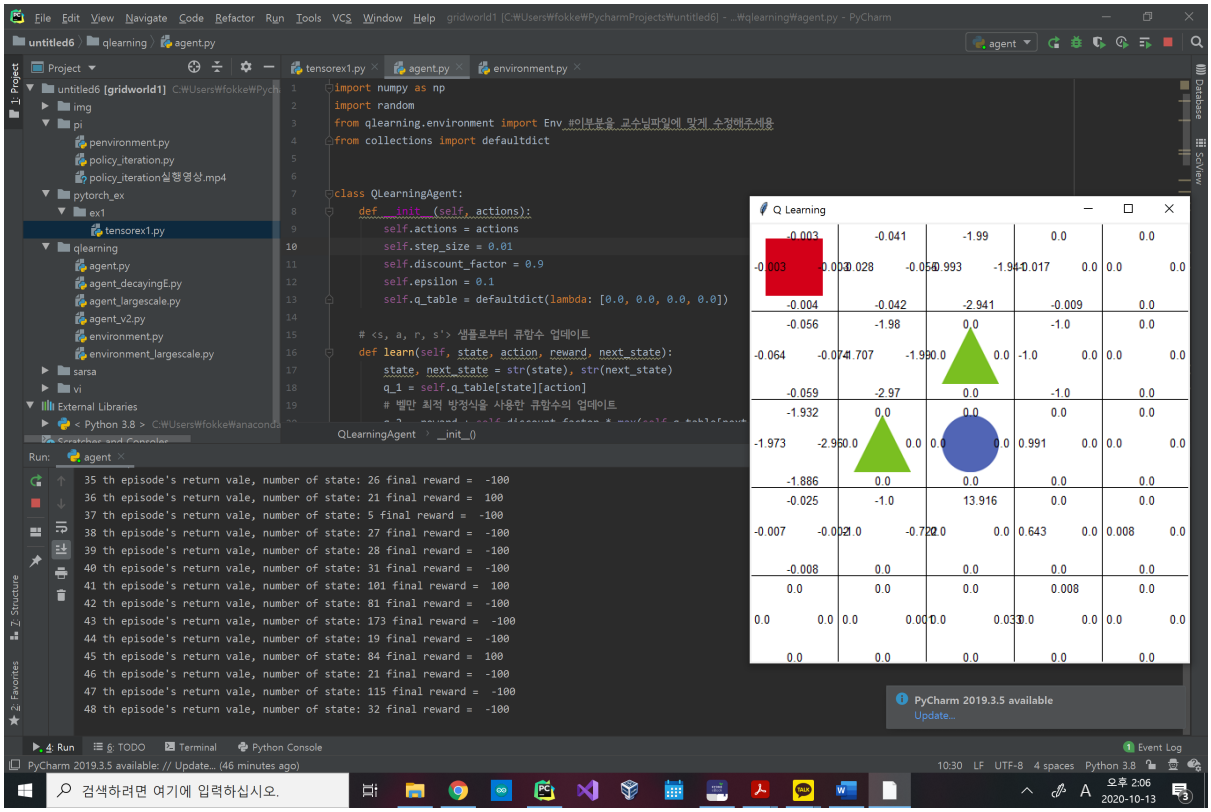

그랬더니 random한 행동으로 인해 q함수값이 아주 이상하게 변해 경로를 찾아가지 못하는 현상을 발견하였습니다.

따라서수정이 필요함을 느껴 수정하였습니다.

$$Q(s,a) \leftarrow r + \gamma \max_{a'} Q(s',a')$$

$$Q(s,a) \leftarrow (1-\alpha)Q(s,a) + \alpha[r + \gamma \max_{a'} Q(s',a')]$$

큐함수를 다음 큐함수에 의해 한번에 업데이트 하는 방식이 아닌 learning rate에 따라 조금씩 현재 큐함수를 업데이트 해나가도록, 즉 현재 큐함수가 다음 큐함수보다 dominant한 term이 되도록 수정해주었습니다.이와 같은 수식으로 큐함수를 바꾸어서 다시 실행해 보았습니다. α(learning rate)값은 0.1로 주었습니다.

```
    # <s, a, r, s'> 샘플로부터 큐함수 업데이트
    def learn(self, state, action, reward, next_state):
        state, next_state = str(state), str(next_state)
        q_1 = self.q_table[state][action]
        # 벨만 최적 방정식을 사용한 큐함수의 업데이트
        q_2 = (1-self.learning_rate)*q_1+self.learning_rate*(reward + self.discount_factor * max(self.q_table[next_state]))
        self.q_table[state][action] += self.step_size * (q_2 - q_1)
```

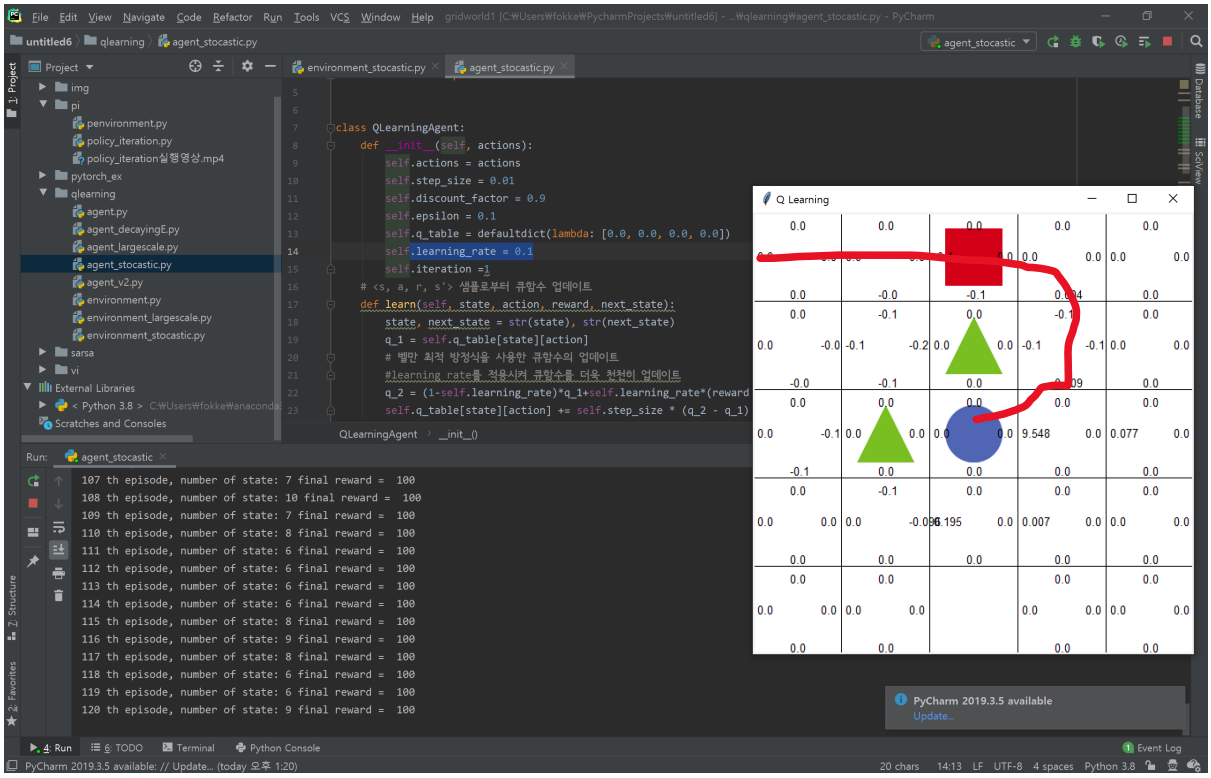

그랬더니 큐함수의 값이 stocastic한 환경에 의해 잘못 계산되어도 그 잘못판단한 것을 현재 큐함수에 조금 반영하여 이후 차차 다시 잘 변하는 것을 확인할 수 있었습니다. 결국 여러 번의 epsoide진행이후 빨간 경로를 따라 잘 학습이 된 것을 확인했습니다.

아래는 최종 실행 영상입니다.