Model-free Reinforcement Learning

Slides from

- 1. 이웅원 외, 파이썬과 케라스로 배우는 강화학습, 주교재
- 2. 이웅원, 가깝고도 먼 DeepRL, PPT
- 3. David Silver, Reinforcement Learning, PPT

References

- 1. Richard S. Sutton and Andrew G. Barto, Reinforcement Learning: An Introduction, MIT Press
- 2. 유튜브, 전민영, 노승은, 강화학습의 기초 이론, 팡요랩

Contents

- 1. 강화학습이 풀고자 하는 문제 : Sequential Decision Problem
- 2. 문제에 대한 수학적 정의 : Markov Decision Process
- 3. MDP를 계산으로 푸는 방법 : Dynamic Programming
- 4. MDP를 학습으로 푸는 방법 : Reinforcement Learning
- 5. 상태공간이 크고 차원이 높을 때 쓰는 방법 : Function Approximation
- 6. 바둑과 같은 복잡하고 어려운 문제를 푸는 방법 : Deep Reinforcement Learning

Model-Free Reinforcement Learning

- Last lecture:
 - Planning by dynamic programming
 - Solve a known MDP
- This lecture:
 - Model-free prediction
 - Estimate the value function of an unknown MDP
- Next lecture:
 - Model-free control
 - Optimise the value function of an unknown MDP

DP vs RL

- DP
 - Model-based Planning
- RL
 - Model-free Learning
 - Prediction (예측) 주어진 정책에 대한 가치함수를 학습
 - -> Monte Carlo (MC), Temporal Difference (TD)
 - Control (제어) 가치함수를 토대로 정책을 발전시켜 최적 정책을 학습
 - -> MC control, SARSA, Q-Learning
- DP vs RL
 - Policy evaluation --> Prediction
 - Policy improvement --> Control

DP vs RL

- DP
 - 환경에 대한 정확한 지식을 가지고 모든 상태에 대해 가치함수를 동시 에 계산
 - -> 차원의 저주 (Curse of Dimensionality)
- RL
 - 에이전트가 격은 경험으로부터 학습
 - 1) 일단 해보고
 - 2) 자신을 평가하며
 - 3) 평가한 대로 자신을 업데이트
 - 4) 위의 과정을 반복


Monte Carlo Approximation

- Monte Carlo Approximation
 - 무작위로 무엇인가를 해본다
 - 샘플을 통해 "원래의 값에 대해 이럴 것이다"라고 추정
 - 샘플의 개수가 많아지면 점점 원래의 값과 비슷해 질 것이다

Monte Carlo Approximation

• 원의 넓이 계산 예

$$\frac{S(A)}{S(B)} \sim \frac{\text{\# of dots } \in A}{\text{\# of dots } \in B}$$



-> 점이 하나의 샘플이고, 점을 찍는 것이 샘플링

샘플링 – 에이전트가 한 번 환경에서 에피소드를 진행하는 것
 -> 샘플링을 통해 얻은 샘플의 평균으로 참 가치함수의 값을 추정


샘플링 + 평균 → 가치함수 추정

• 가치함수


$$v_{\pi}(s) = E_{\pi}[R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots | S_t = s]$$

- 정책평가에서 기대값을 계산하지 않고 샘플링을 통해 샘플들의 평균으로 참가치함수를 예측하려면?
 - -> 현재 정책에 따라서 계속 행동해 보면 됨
 - -> 행동을 하면 그에 따른 보상을 받고,
 - -> 에피소드의 끝까지 가면 반환값을 알 수 있음

$$G_t = R_{t+1} + \gamma R_{t+2} + \cdots + \gamma^{T-t-1} R_T$$



샘플링을 통해 하나의 에피소드를 진행



지나온 상태들의 반환값

• 여러 에피소드를 통해 구한 반환값의 평균을 통해 $v_{\pi}(s)$ 를 추정

$$v_{\pi}(s) \sim \frac{1}{N(s)} \sum_{i=1}^{N(s)} G_i(s)$$

• 상태 s에서의 반환값의 평균

$$v_{\pi}(s) \sim \frac{1}{N(s)} \sum_{i=1}^{N(s)} G_i(s)$$

$$V_{n+1} = \frac{1}{n} \sum_{i=1}^{n} G_i = \frac{1}{n} \left(G_n + \sum_{i=1}^{n-1} G_i \right)$$

$$= \frac{1}{n} \left(G_n + (n-1) \frac{1}{n-1} \sum_{i=1}^{n-1} G_i \right)$$

$$= \frac{1}{n}(G_n + (n-1)V_n)$$

$$= \frac{1}{n}(G_n + nV_n - V_n)$$


$$= V_n + \frac{1}{n}(G_n - V_n)$$

$$\therefore V(s) \leftarrow V(s) + \frac{1}{n}(G(s) - V(s))$$

- 몬테카를로 예측에서 가치함수의 업데이트 식 $V(s) \leftarrow V(s) + \frac{1}{n}(G(s) V(s))$ where error = G(s) V(s), step size = 1/n
- 몬테카를로 예측에서 가치함수의 업데이트 일반식

$$V(s) \leftarrow V(s) + \alpha(G(s) - V(s))$$

$$V(s) \leftarrow V(s) + \alpha(G(s) - V(s))$$



- 1. G(s) = 업데이트의 목표
- 2. $\alpha(G(s) V(s)) = 업데이트의 크기$

Monte Carlo Reinforcement Learning

- MC methods learn directly from episodes of experience
- MC is *model-free*: no knowledge of MDP transitions / rewards
- MC learns from complete episodes: no bootstrapping
- MC uses the simplest possible idea: value = mean return
- Caveat: can only apply MC to episodic MDPs
 - All episodes must terminate

- 몬테카를로 예측의 단점
 - 가치함수를 업데이트하기 위해서는 에피소드가 끝날 때까지 기다려야 함
 - 실시간이 아님
 - 에피소드의 끝이 없거나 에피소드의 길이가 긴 경우에는 적합하지 않음
- 시간차 예측 (Temporal Difference Prediction)
 - 에피소드마다가 아니라 타임스텝마다 가치함수를 업데이트

• 몬테카를로 예측에서의 가치함수 업데이트 식

$$v_{\pi}(s) = \mathbf{E}_{\pi}[G_t | S_t = s]$$
$$V(S_t) \leftarrow V(S_t) + \alpha(G_t - V(S_t))$$


• 시간차 예측에서의 가치함수 업데이트 식

$$v_{\pi}(s) = \mathbf{E}_{\pi}[R_{t+1} + \gamma v_{\pi}(S_{t+1}) | S_t = s]$$
$$V(S_t) \leftarrow V(S_t) + \alpha(R + \gamma V(S_{t+1}) - V(S_t))$$

$$V(S_t) \leftarrow V(S_t) + \alpha(R + \gamma V(S_{t+1}) - V(S_t))$$

where TD error = R + \gamma V(S_{t+1}) - V(S_t)

- 1. $R + \gamma V(S_{t+1}) = 업데이트의 목표$
- $2. \ \alpha(R + \gamma V(S_{t+1}) V(S_t)) = 업데이트의 크기$
- 업데이트의 목표는 실제값이 아닌 에이전트가 가지고 있는 예측치
- Bootstrap : 다른 상태의 가치함수 예측값을 통해 지금 상태의 가치함수를 예측하는 방식



- 어떤 상태에서 행동을 하면 보상을 받고 다음 상태를 알게 되고 다음 상태의 가치함수와 알게 된 보상을 더해 그 값을 업데이트 의 목표로 삼음
- 에피소드가 끝날 때까지 기다릴 필요 없이 바로 가치함수를 업데이트 할 수 있음

Temporal-Difference Learning

- TD methods learn directly from episodes of experience
- TD is *model-free*: no knowledge of MDP transitions / rewards
- TD learns from *incomplete* episodes, by *bootstrapping*
- TD updates a guess towards a guess

MC and TD

- Goal: learn v_{π} online from experience under policy π
- Incremental every-visit Monte-Carlo
 - Update value $V(S_t)$ toward actual return G_t

$$V(S_t) \leftarrow V(S_t) + \alpha \left(G_t - V(S_t) \right)$$

- Simplest temporal-difference learning algorithm: TD(0)
 - Update value $V(S_t)$ toward estimated return $R_{t+1} + \gamma V(S_{t+1})$

$$V(S_t) \leftarrow V(S_t) + \alpha \left(R_{t+1} + \gamma V(S_{t+1}) - V(S_t) \right)$$

- $Arr R_{t+1} + \gamma V(S_{t+1})$ is called the *TD target*
- $\delta_t = R_{t+1} + \gamma V(S_{t+1}) V(S_t)$ is called the *TD error*

Advantages and Disadvantages of MC vs. TD


- TD can learn *before* knowing the final outcome
 - TD can learn online after every step
 - MC must wait until end of episode before return is known
- TD can learn without the final outcome
 - TD can learn from incomplete sequences
 - MC can only learn from complete sequences
 - TD works in continuing (non-terminating) environments
 - MC only works for episodic (terminating) environments

Bias/Variance Trade-Off

- Return $G_t = R_{t+1} + \gamma R_{t+2} + ... + \gamma^{T-1} R_T$ is unbiased estimate of $v_{\pi}(S_t)$
- True TD target $R_{t+1} + \gamma v_{\pi}(S_{t+1})$ is *unbiased* estimate of $v_{\pi}(S_t)$
- TD target $R_{t+1} + \gamma V(S_{t+1})$ is biased estimate of $v_{\pi}(S_t)$
- TD target is much lower variance than the return:
 - Return depends on many random actions, transitions, rewards
 - TD target depends on one random action, transition, reward

Monte-Carlo Backup


$$V(S_t) \leftarrow V(S_t) + \alpha \left(G_t - V(S_t) \right)$$



David Silver, Reinforcement Learning, PPT

Temporal-Difference Backup


$$V(S_t) \leftarrow V(S_t) + \alpha \left(R_{t+1} + \gamma V(S_{t+1}) - V(S_t) \right)$$



David Silver, Reinforcement Learning, PPT

Dynamic Programming Backup

$$V(S_t) \leftarrow \mathbb{E}_{\pi} \left[R_{t+1} + \gamma V(S_{t+1}) \right]$$




David Silver, Reinforcement Learning, PPT

Bootstrapping and Sampling

- Bootstrapping: update involves an estimate
 - MC does not bootstrap
 - DP bootstraps
 - TD bootstraps
- Sampling: update samples an expectation
 - MC samples
 - DP does not sample
 - TD samples

Unified View of Reinforcement Learning




David Silver, Reinforcement Learning, PPT


Model-Free Reinforcement Learning

- Last lecture:
 - Model-free prediction
 - Estimate the value function of an unknown MDP
- This lecture:
 - Model-free control
 - Optimise the value function of an unknown MDP

강화학습 알고리즘의 흐름



Generalised Policy Iteration




Policy evaluation Estimate v_{π}

e.g. Iterative policy evaluation


Policy improvement Generate $\pi' \geq \pi$

e.g. Greedy policy improvement



David Silver, Reinforcement Learning, PPT

Generalised Policy Iteration With Monte-Carlo Evaluation



Policy evaluation Monte-Carlo policy evaluation, $V = v_{\pi}$? Policy improvement Greedy policy improvement?

Model-Free Policy Iteration Using Action-Value Function


• Greedy policy improvement over V(s) requires model of MDP

$$\pi'(s) = \operatorname*{argmax}_{s \in \mathcal{A}} \mathcal{R}^{a}_{s} + \mathcal{P}^{a}_{ss'} V(s')$$

■ Greedy policy improvement over Q(s, a) is model-free

$$\pi'(s) = \underset{a \in \mathcal{A}}{\operatorname{argmax}} Q(s, a)$$

Generalised Policy Iteration with Action-Value Function




Policy evaluation Monte-Carlo policy evaluation, $Q = q_{\pi}$ Policy improvement Greedy policy improvement?

David Silver, Reinforcement Learning, PPT

ε -Greedy Exploration

- Simplest idea for ensuring continual exploration
- All m actions are tried with non-zero probability
- With probability 1ϵ choose the greedy action
- lacktriangle With probability ϵ choose an action at random


Monte-Carlo Policy Iteration



Policy evaluation Monte-Carlo policy evaluation, $Q=q_\pi$ Policy improvement ϵ -greedy policy improvement

David Silver, Reinforcement Learning, PPT

Monte-Carlo Control



Every episode:

Policy evaluation Monte-Carlo policy evaluation, $Q \approx q_{\pi}$ Policy improvement ϵ -greedy policy improvement David Silver, Reinforcement Learning, PPT

Monte-Carlo Control

- Sample *k*th episode using π : $\{S_1, A_1, R_2, ..., S_T\} \sim \pi$
- For each state S_t and action A_t in the episode,

$$egin{aligned} N(S_t,A_t) &\leftarrow N(S_t,A_t) + 1 \ Q(S_t,A_t) &\leftarrow Q(S_t,A_t) + rac{1}{N(S_t,A_t)} \left(G_t - Q(S_t,A_t)
ight) \end{aligned}$$

Improve policy based on new action-value function

$$\epsilon \leftarrow 1/k$$
 $\pi \leftarrow \epsilon$ -greedy(Q)

TD Control


- Temporal-difference (TD) learning has several advantages over Monte-Carlo (MC)
 - Lower variance
 - Online
 - Incomplete sequences
- Natural idea: use TD instead of MC in our control loop
 - Apply TD to Q(S, A)
 - Use ϵ -greedy policy improvement
 - Update every time-step

GPI vs. TD

- GPI(Generalized Policy Iteration)
 - 정책 평가와 정책 발전을 한번씩 번갈아 가면서 진행



- 시간차 예측
 - 타임스텝마다 가치함수를 현재 상태에 대해서만 업데이트
- 시간차 제어



시간차 제어에서의 탐욕 정책

• GPI에서의 정책 발전 식

$$\pi'(s) = argmax_{a \in A}[R_s^a + \gamma P_{ss}^a, V(s')]$$

- -> 환경의 모델인 R_s^a 와 P_{ss}^a , 를 알아야 함
- 큐함수를 사용한 탐욕 정책 식

$$\pi(s) = argmax_{a \in A}Q(s, a)$$


- -> 다음 상태의 가치함수를 보고 판단하는 것이 아니라 현재 상태의 큐함수를 보고 판단
- -> 환경의 모델을 몰라도 됨

강화학습 알고리즘 1: SARSA

• 시간차 제어에서는 큐함수를 업데이트 함


$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha(R + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t))$$

ightharpoonup다음 상태의 큐함수인 $Q(S_{t+1},A_{t+1})$ 를 알기 위해서는 다음 상태 S_{t+1} 에서 다음 행동 A_{t+1} 까지 선택해야 함



▶시간차 제어에서 큐함수를 업데이트하기 위해 [S_t,A_t,R_{t+1},S_{t+1},A_{t+1}]를 샘플로 사용 -> SARSA

Updating Action-Value Functions with Sarsa




$$Q(S,A) \leftarrow Q(S,A) + \alpha \left(R + \gamma Q(S',A') - Q(S,A)\right)$$

강화학습 알고리즘 1: SARSA

• Exploitation vs Exploration $\triangleright \varepsilon$ -greedy 정책


$$\pi(s) = \begin{cases} a^* = argmax_{a \in A}Q(s, a) & 1 - \varepsilon \\ a \neq a^* & \varepsilon \end{cases}$$




강화학습 알고리즘 1: SARSA

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha(R + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t))$$

- 1. ε-greedy 정책을 통해 정책 [S,A,R,+1,S,+1,A,+1]을 획득
- 2. 획득한 샘플로 다음 식을 통해 큐함수 $Q(S_t, A_t)$ 를 업데이트



On-Policy Control With Sarsa





Every time-step:

Policy evaluation Sarsa, $Q \approx q_{\pi}$

Policy improvement ϵ -greedy policy improvement

• SARSA의 한계





- 에이전트가 s'에서 탐험에 따라 아래로 가는 a'을 함 -> Q(s',a')는 -1의 보상을 받음
- 따라서 아래의 큐함수 업데이트 식에 따라 Q(s,a)의 값도 낮아지게 됨 $Q(s,a) \leftarrow Q(s,a) + \alpha(r + \gamma Q(s',a') Q(s,a))$
- $Q(s,a) \leftarrow Q(s,a) + \alpha(r + \gamma Q(s',a') Q(s,a))$ 이후에 에이전트가 다시 s에 오게 되면 오른쪽으로 가는 행동 a'이 안 좋다고 판단함
- 따라서 에이전트가 s에서 오른쪽으로 가지 못하고 갇혀버림

SARSA

- ▶On-Policy : 자신이 행동하는 대로 학습
- ▶탐험을 위해 선택한 ε-greedy 정책 때문에 에이전트는 최적 정책을 학습하지 못하고 오히려 잘못된 정책을 학습


Q-Learning


- ▶Off-Policy : 행동하는 정책과 학습하는 정책을 분리
- ▶행동은 ε-greedy 정책에 따라 선택
- ▶ 큐함수 업데이트는 greedy 정책(가장 큰 큐함수로 업데이트)으로 함

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left(R_{t+1} + \gamma \max_{a'} Q(S_{t+1}, a') - Q(S_t, A_t) \right)$$

▶ 큐함수를 업데이트하기 위해 필요한 샘플은 [s,a,r,s']

Q-Learning





- 에이전트가 s'에서 탐험에 따라 아래 로 가는 a'을 함
- ▶ 하지만 큐함수 업데이트에는 a'을 반 영하지 않고, 그 상태(s')에서 가장 큰 큐함수로 현재 큐함수를 업데이트
- 이후에 에이전트가 다시 s에 오게 되면 아래의 큐함수 업데이트 식에 따라 오른쪽으로 진행할 수 있음 $Q(S_t,A_t)$

$$\leftarrow Q(S_t, A_t) + \alpha \left(R_{t+1} + \gamma \max_{a'} Q(S_{t+1}, a') - Q(S_t, A_t) \right)$$

Q-Learning

- We now consider off-policy learning of action-values Q(s, a)
- No importance sampling is required
- Next action is chosen using behaviour policy $A_{t+1} \sim \mu(\cdot|S_t)$
- But we consider alternative successor action $A' \sim \pi(\cdot|S_t)$
- And update $Q(S_t, A_t)$ towards value of alternative action

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left(R_{t+1} + \gamma Q(S_{t+1}, A') - Q(S_t, A_t) \right)$$

Off-Policy Control with Q-Learning

- We now allow both behaviour and target policies to improve
- The target policy π is greedy w.r.t. Q(s, a)


$$\pi(S_{t+1}) = \operatorname*{argmax}_{a'} Q(S_{t+1}, a')$$

- The behaviour policy μ is e.g. ϵ -greedy w.r.t. Q(s,a)
- The Q-learning target then simplifies:

$$R_{t+1} + \gamma Q(S_{t+1}, A')$$

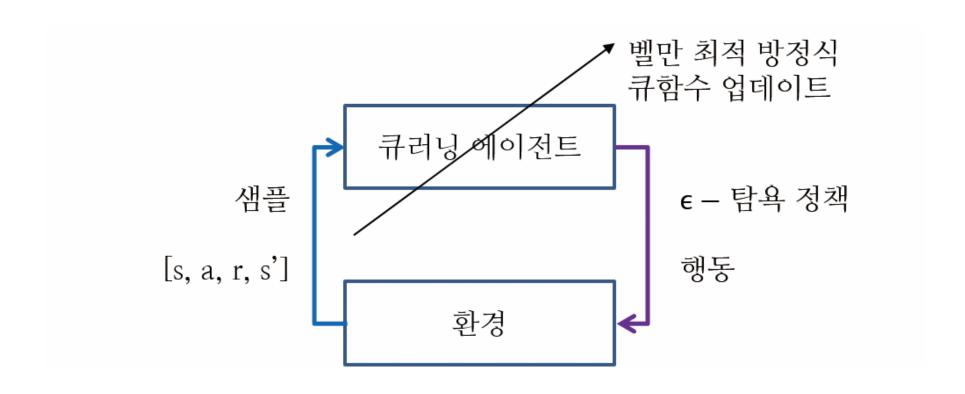
= $R_{t+1} + \gamma Q(S_{t+1}, \underset{a'}{\operatorname{argmax}} Q(S_{t+1}, a'))$
= $R_{t+1} + \max_{a'} \gamma Q(S_{t+1}, a')$

Q-Learning Control Algorithm



$$Q(S, A) \leftarrow Q(S, A) + \alpha \left(R + \gamma \max_{a'} Q(S', a') - Q(S, A)\right)$$

SARSA vs Q-Learning



Relationship Between DP and TD

	Full Backup (DP)	Sample Backup (TD)
Bellman Expectation	$v_{\pi}(s) \leftrightarrow s$ $v_{\pi}(s') \leftrightarrow s'$	
Equation for $v_{\pi}(s)$	Iterative Policy Evaluation	TD Learning
Bellman Expectation	$q_{\pi}(s,a) \leftarrow s,a$ r s' $q_{\pi}(s',a') \leftarrow a'$	S,A R S' A'
Equation for $q_{\pi}(s,a)$	Q-Policy Iteration	Sarsa
Bellman Optimality	$q_{\bullet}(s,a) \leftrightarrow s,a$ r s' $q_{\bullet}(s',a') \leftrightarrow a'$	
Equation for $q_*(s, a)$	Q-Value Iteration avid Silver, Reinforcement Learning, PPT	Q-Learning

Relationship Between DP and TD (2)

Full Backup (DP)	Sample Backup (TD)	
Iterative Policy Evaluation	TD Learning	
$V(s) \leftarrow \mathbb{E}\left[R + \gamma V(S') \mid s\right]$	$V(S) \stackrel{\alpha}{\leftarrow} R + \gamma V(S')$	
Q-Policy Iteration	Sarsa	
$Q(s, a) \leftarrow \mathbb{E}\left[R + \gamma Q(S', A') \mid s, a\right]$	$Q(S,A) \stackrel{\alpha}{\leftarrow} R + \gamma Q(S',A')$	
Q-Value Iteration	Q-Learning	
$Q(s, a) \leftarrow \mathbb{E}\left[R + \gamma \max_{a' \in \mathcal{A}} Q(S', a') \mid s, a\right]$	$Q(S,A) \stackrel{\alpha}{\leftarrow} R + \gamma \max_{a' \in A} Q(S',a')$	

where
$$x \stackrel{\alpha}{\leftarrow} y \equiv x \leftarrow x + \alpha(y - x)$$

Summary

• 몬테카를로 예측

$$V(S_t) \leftarrow V(S_t) + \alpha(G_t - V(S_t))$$

• 시간차 예측

$$V(S_t) \leftarrow V(S_t) + \alpha(R + \gamma V(S_{t+1}) - V(S_t))$$

MC Control

$$Q(s,a) \leftarrow Q(s,a) + \alpha(G_t - Q(s,a))$$

SARSA

$$Q(s,a) \leftarrow Q(s,a) + \alpha(r + \gamma Q(s',a') - Q(s,a))$$

Q-Learning

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left(R_{t+1} + \gamma \max_{a'} Q(S_{t+1}, a') - Q(S_t, A_t) \right)$$